CHORD：面向多模态大语言模型的物体共振解码幻觉校准

Calibrating Hallucinations via Object-Resonant Decoding in Multimodal Large Language Models

Anonymous Author(s)

Abstract

多模态大语言模型（MLLM）在跨模态理解与生成上已取得显著进展，但仍持续受幻觉问题困扰，即生成与视觉输入不一致的文本。我们指出，其根本原因之一在于自回归解码阶段的**跨模态粒度失配**：图像被编码为连续的整体特征，而文本必须以离散、且常呈语义碎片化的子词（sub-word）token 序列输出；这使得难以将无独立语义的单 token 可靠地锚定到具体视觉实体，模型易进入未经验证的解码状态，语言先验的统计惯性进而放大幻觉。现有缓解策略往往依赖昂贵重训或高代价的多轮验证。为此，我们提出 **CHORD**（Calibrating Hallucinations via Object-Resonant Decoding，通过物体共振解码校准幻觉）——一种**免训练**、可即插即用的解码框架，借助 **Object-Resonant Decoding（物体共振解码）**将生成轨迹重新锚定到视觉事实。CHORD 在活跃解码前沿上工作，动态评估**候选文本片段**与**外部视觉证据**的对齐程度：仅当片段与具体视觉物体在语义上“共振”时增强其概率，而对仅由语言惯性驱动的无根据内容予以抑制。为在控制开销的同时捕获**过度自信型**幻觉，我们采用**连续 Top-1 监控**并在必要时**回退到全 K 候选**的共振计算，并利用外部文本编码器的 KV 缓存复用，使完整前沿评分仅在 Top-1 假设未通过共振检验时触发。在多个面向幻觉的基准上，CHORD 显著降低物体幻觉；作为与宿主架构解耦的框架，它无需额外训练，为可信 MLLM 部署提供可扩展路径。

CCS Concepts

• **Computing methodologies → Artificial intelligence**; *Machine learning*.

Keywords

多模态大语言模型, 幻觉缓解, 解码时干预, 物体共振解码, CHORD, 接地

ACM Reference Format:
Anonymous Author(s). 2026. CHORD：面向多模态大语言模型的物体共振解码幻觉校准: *Calibrating Hallucinations via Object-Resonant Decoding in Multimodal Large Language Models.* In *Proceedings of ACM Multimedia 2026 (MM '26)*. ACM, New York, NY, USA, 5 pages. https://doi.org/10.1145/XXXXXXX.XXXXXXX

1 引言

多模态大语言模型（MLLM）已推动视觉问答、图像描述与开放式多模态推理快速发展，但即使是强模型仍易出现幻觉：生成流畅却接地不足、虚构图像中不存在的物体，或在强语言先验下对视觉不支持的实体过度自信。当正确证据稀疏、局部化或被无关视觉上下文淹没时，这类失败尤为有害。

近期工作表明，**推理期干预**是替代重训宿主模型的有效途径。对比解码（如 VCD）、基于注意力的控制（如 OPERA）以及层间对比解码（如 DoLa）均将自回归解码视为可操作的干预面。然而，仍存在更严格的问题：

> **解码期缓解能否在异构 MLLM 家族间保持可迁移性——无需按模型单独训练，且不依赖宿主内部的隐状态、logit 或注意力？**

该目标不同于单点提升骨干性能。任何消费模型特异多模态激活、并在宿主原生几何中写入校正的方法，即便视觉—语言权重冻结，仍属**宿主耦合**。**隐状态校准**类路线说明了这一现象，但难以满足严格的即插即用可迁移要求。

因此我们提出**可迁移性边界**：机制若完全运行于模型原生的隐空间、logit 空间或注意力空间内，则无法实现严格意义上的热插拔。可检验的替代方案是将所有评分限制在由**冻结的公开视觉特征**、**冻结文本编码器**、**解码得到的候选片段**以及**确定性**分词器桥接所构成的**共享外部空间**中，且不引入绑定于特定宿主的可学习适配器。

CHORD（Calibrating Hallucinations via Object-Resonant Decoding）体现该原则。它执行**候选驱动的视觉共振**：关键信号并非未完成前缀与图像的全局相似度，而是**当前候选片段**是否激活一致的局部视觉证据，以及该证据是否支持干预。缓解被刻画为对与候选绑定的外部、物体级证据的选择性调用，而非对无关区域或纯语言延续偏置的整体重分配。

由此有两点推论：其一，除原始幻觉降幅外，还应在**外部编码器与区域库固定、仅分词器桥接随宿主确定性变化**的前提下，考察 CHORD 在**不同宿主家族**上是否**稳定**；其二，基于稠密区域库的片段级共振应明显优于朴素的全局图像先验，否则额外机制难以自证必要。

本文贡献如下：

(1) 形式化限制宿主内部解码器严格可移植控制的**可迁移性边界**。
(2) 提出 **CHORD：免训练**解码框架，在外部嵌入空间中利用物体共振证据与闭式**共振增量** ΔS 校准活跃 logit 前沿。
(3) 引入**无参数分词器桥接**及**连续 Top-1 监控**（配合全 K 回退），使共振检验轻量，并在不依赖朴素熵门控的前提下抑制过度自信幻觉。
(4) 在 POPE、CHAIR 上给出含解码基线、消融与效率分析的**评估协议**。

全文结构：第 2 节为相关工作；第 3 节给出边界与 CHORD 方法；第 4 节为实验；第 5 节为结论。

2 相关工作

2.1 多模态幻觉评估与基准

视觉—语言模型中的幻觉评估已形成若干互补协议。**CHAIR** [7] 衡量生成描述中提及的物体是否被图像所支持，表明流畅文本仍可能视觉不成立。**POPE** [5] 将评估转化为平衡的物体存在性是非题，在受控提示下度量幻觉并揭示对语言先验的敏感。**AMBER** [9] 将视角扩展到属性、关系等多类错误，避免将“仅物体级”分数等同于完整多模态忠实度。三者回答的问题不同：CHAIR 面向开放式描述；POPE 面向判别式探测；AMBER 强调多面失效模式，不宜互相替代。

MM '26, TBD
2026. ACM ISBN 978-1-4503-XXXX-X/2026/XX
https://doi.org/10.1145/XXXXXXX.XXXXXXX

更大规模的判别套件在任务与上下文结构上进一步扩展。**PhD** [6] 提供大规模 VQA 式基准，含多种识别任务与对抗式提问模式，用于检验 MLLM 在视觉误导或先验触发场景下的鲁棒性。本文以 CHAIR 与 POPE 为主要汇报轴（第 4 节），并将此类更广评估脉络作为未来压力测试的背景。

2.2 解码期缓解与控制

一类重要方法在**不更新权重**的前提下于自回归解码过程中干预。**视觉对比解码（VCD）**[4] 对比完整视觉与扰动视觉条件下的 logit，以抑制语言先验驱动的物体。**OPERA** [2] 利用注意力与回溯信号约束生成轨迹。**DoLa** [1] 源于纯文本 LM，通过对比浅层与深层 logit 提升事实性；迁移到 MLLM 后仍是强的**内部**层间基线，但本身并不在外部视觉空间中强制物体级接地。

近期面向 MLLM 的解码改进仍主要**读取或重塑内部表示**。例如 **DeCo** [8] 在浅层似乎仍保留视觉证据而深层被语言先验压制时，动态融合更早层的 logit。这类设计说明栈内仍存在有用视觉信号，但也继承了需访问宿主层输出与几何的可迁移性限制。

CHORD 与第 3 节强调的两条轴线一致：（i）**不**消费宿主隐状态或注意力张量——仅使用短候选前沿上的 logit 与确定性分词器前瞻；（ii）在**冻结**的区域级视觉库与**冻结**的公开文本编码器上对**候选片段**打分，使干预信号定义于共享外部空间。其针对子词提议与物体级证据之间的**粒度**鸿沟，并以连续 Top-1 监控控制片段级评分开销。

2.3 后处理、偏好优化及与 CHORD 的关系

互补路线在生成**之后**修改输出，或直接更新模型。**LURE** [12] 基于与物体幻觉相关的统计因素做轻量后修。**Woodpecker** [10] 通过多阶段工具流水线抽取主张、查询外部视觉模块并重写不一致文本。**Volcano** [3] 迭代自反馈与修订。**HA-DPO** [11] 通过偏好优化持久改变模型行为。正因不受逐步解码预算约束，它们才能使用更丰富验证或更强监督。

CHORD 针对更窄设定：在 top-K 前沿上**免训练、解码内**校准，依赖外部物体级证据与提升后片段上的闭式共振增量 ΔS。时间轴上与解码基线 [1, 2, 4, 8] 最接近，证据形态上接近工具增强路线 [10]，但避免完整后处理流水线且不做偏好更新 [11]。第 3 节进一步说明该设计与可迁移性边界及抑制过度自信幻觉（不唯熵门控）的关系。

3 方法

3.1 可迁移性边界与粒度失配

若解码期干预模块的输入或输出具有宿主特异性，则难以称为严格通用。早期校准方法读取模型原生隐状态并投影到宿主词表几何中，此类可学习映射按构造即与宿主耦合，无法在无重训情况下迁移到异构 MLLM。

要实现真正的热插拔，干预须运行于标准化的外部语义空间。设计外部控制器又必须直面幻觉的根本动因之一：**跨模态粒度失配**。MLLM 将图像编码为连续、整体化的特征图，而自回归生成却输出离散、常呈碎片化的子词 token（例如 `["gi", "##raf", "##fe"]`）。在连续视觉实体与无语义碎片 token 之间建立可靠物理接地极为困难。粒度崩塌使模型陷入*开环解码*：视觉校验失效，语言先验惯性压倒视觉约束。CHORD 旨在弥合该失配并闭合解码回路。

3.2 CHORD 框架概述

CHORD（Calibrating Hallucinations via Object-Resonant Decoding）为免训练、即插即用解码框架。它不覆盖全词表分布，仅作用于宿主在步 t 的活跃解码前沿

$$\mathcal{F}_t = \text{Top-}K(L_t), \tag{1}$$

其中 L_t 为原始 logit。流程含四阶段：（1）分词器桥接；（2）连续共振监控；（3）假设驱动共振增量；（4）logit 校准。

生成前，CHORD 对输入图像 I 做一次离线提取：冻结的外部视觉编码器构建稠密局部区域特征库 $\mathcal{Z}_R = \{z_{R_1}, z_{R_2}, \dots, z_{R_N}\}$，作为后续共振核验的静态 "物理事实" 缓存。

3.3 无参数分词器桥接

为克服粒度失配，CHORD 不直接对原始 token ID 评分。设 B_m 为与宿主 m 关联的**无参数**分词器桥接。对每个候选 $c_k \in \mathcal{F}_t$，桥接利用分词器前缀树做确定性前瞻，将 token 提升为语义完整的文本片段 A_k，得到候选片段集 $\mathcal{S}_t = \{A_1, \dots, A_K\}$。桥接不含可学习参数，是将模型特异的碎片化提议转为跨模型、可物理接地的语义命题的关键。

3.4 假设驱动的共振增量

CHORD 将解码建模为物理共振过程：将前缀 p 与候选片段 A_k 拼接视为指向区域库 $\mathcal{Z}_R$ 的 "语义声纳"。为严格避免空间错配（前缀与候选对齐到无关区域），共振增量锚定在**同一**物理区域上。首先为联合假设选取最相关区域：

$$r^* = \arg\max_{r \in \mathcal{Z}_R} \cos\big(E_{\text{text}}(p \oplus A_k), z_r\big), \tag{2}$$

其中 E_{text} 为冻结公开文本编码器。再定义**共振增量** ΔS，刻画加入 A_k 的纯物理效应：

$$\Delta S(A_k) = \cos\big(E_{\text{text}}(p \oplus A_k), z_{r^*}\big) - \cos\big(E_{\text{text}}(p), z_{r^*}\big). \tag{3}$$

该式起到**无启发式**判别作用：（1）$\Delta S > 0$ 表示视觉支持或正确空间关系；（2）$\Delta S < 0$ 表示与图像矛盾（如虚构物体）；（3）$\Delta S \approx 0$ 对应抽象词或语法词，CHORD 可安全忽略而无需脆弱 POS 标注。

3.5 克服过度自信：连续监控与系统优化

朴素熵门控难以捕获**过度自信幻觉**（低熵仍错）。CHORD 弃用纯熵门控，采用**连续 Top-1 监控与全 K 回退**，并结合 E_{text} 的 KV 缓存。前缀 p 持续缓存；$p \oplus A_k$ 往往只需再前向 1–2 个 token。每步对宿主最自信 token 计算 $\Delta S(A_{\text{top1}})$：若 $\Delta S(A_{\text{top1}}) \geq 0$ 则直接接受；若 < 0 则触发对全部 K 个候选的完整共振评估以寻找接地替代。该策略在抑制过度自信的同时控制计算开销。

3.6 Logit 校准

触发完整干预时，CHORD 将共振证据注入宿主 logit。与片段 A_k 对应的候选 token c_k 的调整 logit 为

$$\tilde{L}_t(c_k) = L_t(c_k) + \alpha \cdot \Delta S(A_k), \tag{4}$$

α 为强度超参；再经 softmax 归一化。有界重分配使轨迹向视觉事实偏转，同时尽量不破坏宿主语言结构且无需更新参数。

4 实验

为验证 CHORD，实验围绕四个研究问题展开：

RQ1（有效性与可迁移性）：CHORD 能否在**无模型特异重训**的前提下，在异构 MLLM 家族上一致缓解物体幻觉？

（插图占位）CHORD 流水线：宿主 Top-K 前沿 → 无参数分词器桥接 → 冻结文本/视觉编码器与区域库 → 共振增量 ΔS → 对 $\mathcal{F}_t$ 的有界 logit 校准。

Figure 1: 解码期 CHORD 接入示意图（占位）。

RQ2（泛化性）：CHORD 能否推广到开放式生成，而不损害宿主的结构与语言能力？

RQ3（机制消融）：分词器桥接、共振增量 ΔS 等各组件如何贡献最终性能？

RQ4（系统效率）：连续 Top-1 监控能否将额外计算控制在可忽略水平？

4.1 实验设置

模型与基线。我们在 Qwen-VL（如 Qwen-VL-Chat）、LLaVA-1.5、InstructBLIP 三类家族上评估。对比基线包括标准自回归解码（Base）及三种免训练解码基线：**DoLa**、**OPERA**、**VCD**。

基准。使用 **POPE**（random / popular / adversarial 划分）做系统物体幻觉评估，**CHAIR** 评估开放式图像描述中的幻觉率。

实现细节。 CHORD 无参数更新。区域缓存使用 Grounding DINO 与冻结 CLIP ViT-L/14；共振探针使用 CLIP 文本编码器。

4.2 主结果：幻觉缓解（RQ1）

表 1 汇总 POPE（random 划分）主结果。CHORD 相对 Base 一致提升；在外部、与宿主内部几何解耦的语义空间中计算 ΔS，可抑制语言先验驱动错误。POPE 的 popular 与 adversarial 划分及扩展结果见补充材料，CHORD 保持稳定收益。

4.3 泛化与结构保持（RQ2）

仅在判别任务（如 POPE）上降幻觉不足；若破坏流畅描述能力则不可取。表 **??** 报告 CHAIR-s（句级）与 CHAIR-i（实例级）。有界 logit 校准旨在仅惩罚与视觉矛盾实体，尽量保留宿主句法与推理习惯。

4.4 消融实验（RQ3）

表 **??** 在 Qwen-VL（POPE）上消融。**去掉分词器桥接**、直接对原始子词做共振会导致性能崩溃，说明弥合粒度失配是外部评估的前提。**用绝对相似度替代** ΔS 易产生空间错配（前缀与候选对齐到不同区域），F1 下降。**仅用全局图像特征**、不用稠密区域库则损失细粒度证据，缓解效果减弱。

4.5 系统效率（RQ4）

表 **??** 在 Qwen-VL 上审计开销。每步全 K 共振代价高；**连续 Top-1 监控**在 Top-1 假设通过检验时以 $O(1)$ 过滤安全或非视觉 token，仅在未通过时回退全 K。结合文本编码器 KV 缓存，每步额外延迟相对宿主 MLLM 总体推理保持较小。

5 结论

本文指出现代 MLLM 的一个结构性问题：**跨模态粒度失配**。连续视觉特征与离散、碎片化的子词 token 之间的不一致，使自回归生成易处于未经验证的*开环解码*状态，语言先验惯性常压倒视觉约束，从而催化物体与关系幻觉。

针对该根因，我们提出 **CHORD**（Calibrating Hallucinations via Object-Resonant Decoding）：通过无参数分词器桥接将碎片 token 提升为语义完整片段，在外部共享语义空间中计算**共振增量** ΔS，在避免脆弱启发式与沉重黑盒评估器的同时，强化视觉一致内容并抑制虚构描述。

我们进一步用配备 KV 缓存加速的**连续 Top-1 监控**替代朴素熵门控，在控制开销的同时仍能有效应对过度自信型幻觉。

多宿主家族上的实验表明，CHORD 在显著抑制物体幻觉的同时，尽量保持语言流畅性。结果表明，通过外部物体共振解码可实现强且可跨模型的接地控制，为更可信的 MLLM 部署提供可扩展范式。

A 补充材料

POPE 在 popular 与 adversarial 划分上的补充结果、实现细节与超参设置见补充材料。正文表 1 报告 random 划分；CHORD 在其他划分上保持一致的收益趋势。

References

[1] Yung-Sung Chuang, Yujia Xie, Hongyin Luo, Yoon Kim, James Glass, and Pengcheng He. 2024. DoLa: Decoding by Contrasting Layers Improves Factuality in Large Language Models. In *Proceedings of the International Conference on Learning Representations (ICLR)*. arXiv:2309.03883

[2] Yuheng Huang, Jiayang Bai, Jiazhi Guan, Yiqing Shen, Yung-Hui Li, and Yun Fu. 2024. OPERA: Alleviating Hallucination in Multi-Modal Large Language Models via Over-Trust Penalty and Retrospection-Allocation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. arXiv:2311.17911

[3] Seongyun Lee, Sue Hyun Park, Yongrae Jo, and Minjoon Seo. 2024. Volcano: Mitigating Multimodal Hallucination through Self-Feedback Guided Revision. In *Proceedings of the North American Chapter of the Association for Computational Linguistics (NAACL)*. arXiv:2311.07362

[4] Sicong Leng, Hang Zhang, Guanzheng Chen, Xin Li, Shijian Lu, Chunyan Miao, and Lidong Bing. 2024. Mitigating Object Hallucinations in Large Vision-Language Models through Visual Contrastive Decoding. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. arXiv:2311.16922

[5] Yifan Li, Yifan Du, Kun Zhou, Jinpeng Wang, Wayne Xin Zhao, and Ji-Rong Wen. 2023. Evaluating Object Hallucination in Large Vision-Language Models. In *Proceedings of EMNLP*. arXiv:2305.10355

[6] Jiazhen Liu, Yuhan Fu, Ruobing Xie, Runquan Xie, Xingwu Sun, Fengzong Lian, Zhanhui Kang, and Xirong Li. 2025. PhD: A ChatGPT-Prompted Visual Hallucination Evaluation Dataset. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*. arXiv:2403.11116

[7] Anna Rohrbach, Lisa Anne Hendricks, Kaylee Burns, Trevor Darrell, and Kate Saenko. 2018. Object Hallucination in Image Captioning. In *Proceedings of the Conference on Empirical Methods in Natural Language Processing (EMNLP)*. arXiv:1809.02156 [cs.CV]

[8] Chenxi Wang, Xiang Chen, Ningyu Zhang, Bozhong Tian, Haoming Xu, Shumin Deng, and Huajun Chen. 2024. MLLM can see? Dynamic Correction Decoding for Hallucination Mitigation. *arXiv preprint arXiv:2410.11779* (2024).

[9] Junyang Wang, Yuhang Wang, Guohai Xu, Jing Zhang, Yukai Gu, Haitao Jia, Jiaqi Wang, Haiyang Xu, Ming Yan, Ji Zhang, and Jitao Sang. 2023. AMBER: An LLM-free Multi-dimensional Benchmark for MLLMs Hallucination Evaluation. *arXiv preprint arXiv:2311.07397* (2023).

[10] Shukang Yin, Chaoyou Fu, Sirui Zhao, Tong Xu, Hao Wang, Dianbo Sui, Yunhang Shen, Ke Li, Xing Sun, and Enhong Chen. 2024. Woodpecker: Hallucination Correction for Multimodal Large Language Models. *Science China Information Sciences* (2024). arXiv:2310.16045 doi:10.1007/s11432-024-4251-x

[11] Zhiyuan Zhao, Bin Wang, Linke Ouyang, Xiaoyi Dong, Jiaqi Wang, and Conghui He. 2023. Beyond Hallucinations: Enhancing LVLMs through Hallucination-Aware Direct Preference Optimization. *arXiv preprint arXiv:2311.16839* (2023).

[12] Yiyang Zhou, Chenhang Cui, Jaehong Yoon, Linjun Zhang, Zhun Deng, Chelsea Finn, Mohit Bansal, and Huaxiu Yao. 2024. Analyzing and Mitigating Object Hallucination in Large Vision-Language Models. In *Proceedings of the International Conference on Learning Representations (ICLR)*. OpenReview: https://openreview.net/forum?id=oZDJKTlOUe.

Table 1: POPE 基准（random 划分）主结果。TBD 表示定稿待填数值。

宿主模型	方法	Acc	Prec	Recall	F1
Qwen-VL	Base	TBD	TBD	TBD	TBD
	DoLa	TBD	TBD	TBD	TBD
	OPERA	TBD	TBD	TBD	TBD
	VCD	TBD	TBD	TBD	TBD
	CHORD（本文）	**0.9153**	**0.9822**	**0.8460**	**0.9090**
LLaVA-1.5	Base	TBD	TBD	TBD	TBD
	DoLa	TBD	TBD	TBD	TBD
	OPERA	TBD	TBD	TBD	TBD
	VCD	TBD	TBD	TBD	TBD
	CHORD（本文）	**TBD**	**TBD**	**TBD**	**TBD**
InstructBLIP	Base	TBD	TBD	TBD	TBD
	CHORD（本文）	**TBD**	**TBD**	**TBD**	**TBD**